

Trabajo final: Reconocimiento de Patrones - Grad-CAM

Facultad de Cs. Exactas y Naturales - UBA

Damián Care y Gastón Bujía

24/09/2025

Índice

1. Introducción

- a. Explicaciones visuales en modelos de redes profundas

2. Antecedentes

- a. Occlusion Maps
- b. Guided Backpropagation
- c. CAM

3. GradCAM

- a. Explicación
- b. Ejemplos clasificación: ResNet50, VGG16, etc.
- c. Ejemplos otras tareas: Automatic Captioning
- d. Ventajas y desventajas

4. Mejoras: GradCAM++ y otros métodos

5. Referencias

1. Introducción

La explicabilidad en redes neuronales convolucionales (CNN) ha surgido como un aspecto clave en el campo del reconocimiento de patrones, donde no solo interesa alcanzar un alto rendimiento del modelo, sino también comprender qué información utiliza la red para tomar decisiones. Un primer avance clave fueron los **Class Activation Mapping (CAM, 2016)**, que permitieron visualizar las regiones más relevantes de una imagen para la clasificación,

aunque con la limitación de aplicarse únicamente a arquitecturas convolucionales específicas que incluyan un *global average pooling* previo a la capa de clasificación densa. Sin embargo, no fue hasta que apareció **Grad-CAM (Selvaraju et al, 2017)** que amplió esta idea utilizando gradientes retropropagados sobre las predicciones y la activación de las capas, logrando un método versátil aplicable a una amplia variedad de arquitecturas y tareas, consolidándose como la técnica de referencia en explicabilidad. A partir de allí se desarrollaron extensiones como **Grad-CAM++ (2018)**, que mejora la localización en escenarios complejos, o **Score-CAM (2019)**, que evita depender directamente de los gradientes. Grad-CAM dio un salto conceptual decisivo que abrió la puerta al estudio moderno de la explicabilidad y en este trabajo pretendemos dar un panorama al respecto, analizando sus fundamentos, aplicaciones y comparativas con otros métodos. En este trabajo exploraremos los fundamentos de Grad-CAM, su implementación práctica viendo algunos ejemplos y comentaremos brevemente algunas de sus extensiones y mejoras. Para esto replicaremos algunos de los experimentos presentados en el paper original y realizaremos algunos adicionales comparando diferentes arquitecturas de redes neuronales o diferentes tareas.

2. Antecedentes

Uno de los grandes desafíos en el uso de redes neuronales profundas es su naturaleza de "caja negra", que dificulta entender cómo y por qué toman ciertas decisiones, es difícil responder preguntas del estilo de cuáles son los features de la instancia que están influyendo en la predicción. Aunque hoy en día se entiende mucho más en detalle su funcionamiento, particularmente en el caso de las convolucionales, la interpretabilidad sigue siendo un área muy activa de investigación en el reconocimiento de patrones.

En respuesta a esta problemática, se han desarrollado diversas técnicas para generar explicaciones visuales que ayuden a interpretar el comportamiento de estos modelos. A continuación, se describen brevemente algunas de las técnicas más relevantes que preceden (e influyen) a Grad-CAM:

Occlusion Maps

Los **Occlusion Maps** (Zeiler et al., 2014) son tal vez uno de los métodos más sencillos, intuitivos y directos para generar explicaciones visuales en redes neuronales. La idea central consiste en evaluar la sensibilidad de la predicción de la red cuando partes de la entrada son ocultadas (ocluidas) o reemplazadas por un valor neutro (por ejemplo, un parche negro o ruido). En la práctica, se recorre la imagen aplicando una "ventana de oclusión" que cubre sistemáticamente diferentes regiones, y se mide cómo varía la probabilidad asociada a la clase objetivo. La salida es un mapa que se proyecta sobre la imagen original y representa el valor medio del decaimiento de la probabilidad de la clase objetivo al ocultar cada región.

Las zonas donde la predicción se ve más afectada se interpretan como las más relevantes para la decisión del modelo.

Este enfoque tiene varias ventajas: es sencillo de implementar, no depende de modificaciones en la arquitectura del modelo ni de los gradientes, y produce mapas de importancia fáciles de interpretar. No obstante, también presenta desventajas: es computacionalmente costoso (ya que requiere múltiples inferencias por imagen), la resolución depende del tamaño del parche usado, y no captura bien interacciones complejas entre diferentes regiones de la entrada. A pesar de estas limitaciones, Occlusion Maps es un método de referencia en la literatura y se utiliza frecuentemente como baseline en estudios de explicabilidad (ver por ejemplo Samek et al., 2019).

Guided Backpropagation

Guided Backpropagation (Springenberg et al., 2014; Montavon et al., 2018) es un método de visualización que busca identificar qué regiones de una imagen influyen positivamente en la activación de una clase objetivo dentro de una red neuronal profunda. A diferencia del backpropagation estándar, este enfoque modifica el flujo de gradientes en las funciones de activación ReLU, permitiendo únicamente el paso de aquellos gradientes positivos asociados a activaciones positivas. El resultado es un mapa de sensibilidad de alta resolución que resalta bordes y detalles finos de la entrada, mostrando qué píxeles contribuyen a la predicción. Sin embargo, no es estrictamente clase-específico, ya que puede resaltar patrones que activan la red independientemente de la salida seleccionada. Por este motivo, suele utilizarse en combinación con Grad-CAM, logrando visualizaciones más interpretables y centradas en la clase de interés.

CAM

CAM fue introducido por Zhou et al. (2016) y se basa en la utilización de una capa de *global average pooling* (GAP) antes de la capa final de clasificación. La idea es que los pesos de la capa de salida pueden emplearse para ponderar los mapas de activación de la última capa convolucional, generando así un mapa de calor que indica las regiones de la imagen más relevantes para una clase determinada.

Se contruyen los mapas de activacion para cada clase de interes como:

$$M_c(x, y) = \sum_k w_k^c f_k(x, y)$$

donde:

- $M_c(x, y)$ es el mapa de activación para la clase c ,
- $f_k(x, y)$ es el mapa de activación de la característica k ,
- w_k^c es el peso asociado a la clase c en la capa de salida.

Además de requerir global average pooling, CAM solo puede aplicarse a capas cuya última capa sea una red densa. Un uso interesante es la posibilidad de hacer localización de objetos mediante una red que no haya sido entrenada con bounding boxes.

3. Grad-CAM

Metodología

La idea central de Grad-CAM es aprovechar los gradientes de la clase de interés respecto a los mapas de activación de una capa convolucional para generar un mapa de calor que indique qué partes de la entrada influyen más en la predicción. Intuitivamente, esto equivale a preguntarse: si modifico esta región de la imagen, ¿cuánto cambia la confianza del modelo en la clase que me interesa? De esta manera, se obtienen explicaciones visuales que ayudan a interpretar cómo la red toma sus decisiones.

Propuesto por Selvaraju et al. (2017), Grad-CAM generaliza la técnica CAM para que pueda aplicarse a una mayor variedad de arquitecturas, sin depender de capas de *global average pooling*. Para poder computar el mapa de explicabilidad debemos calcular los gradientes de la clase de interés respecto a los mapas de activación, promediarlos para obtener un peso por canal, y finalmente combinarlos para formar un mapa de activación ponderado.

Fórmula principal:

Dada una instancia de entrada y una clase de interés c :

1. Elegimos una capa convolucional de interés (en general la más cercana a la salida ya que es la que suele traer la información mas relevante para la tarea) y calculamos los gradientes asociados a la clase c respecto a los mapas de activación A^k de dicha capa:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

donde: 2. Luego, debemos generar el mapa de activación como:

- y^c es la puntuación (logit) de la clase c antes de aplicar softmax
- A_{ij}^k es la activación en la posición espacial (i, j) del mapa de características k
- Z es el número total de píxeles en el mapa de activación (para promediar)
- α_k^c representa la importancia del canal k para la clase c

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right)$$

donde ReLU asegura que solo se conserven las contribuciones positivas.

La intuición detrás de Grad-CAM es que los gradientes proporcionan una medida de sensibilidad, indicando qué tan importante es cada característica para la predicción de la clase objetivo. Al combinar esta información con los mapas de activación, se obtiene una visualización que resalta las regiones de la imagen que más influyen en la decisión del modelo.

Ventajas y limitaciones

Grad-CAM es una técnica muy versátil, ya que puede aplicarse a una amplia gama de arquitecturas de redes neuronales sin requerir modificaciones específicas como el uso de capas global average pooling. Esto le da la capacidad de generar explicaciones visuales interpretables en distintos tipos de tareas, incluyendo clasificación de imágenes, detección de objetos, automatic captioning o segmentación semántica, lo que lo convierte en una herramienta de gran valor para comprender y depurar modelos complejos. Aun así, presenta ciertas limitaciones: la resolución espacial de los mapas de calor depende fuertemente de la capa convolucional elegida, lo que suele implicar representaciones relativamente gruesas con poco detalle local. Además, tiende a resaltar regiones amplias de la imagen sin capturar con precisión los contornos finos de los objetos, lo que puede reducir su utilidad en escenarios donde se requiere un nivel de explicación más detallado.

A continuación, se presentan algunos ejemplos prácticos de la aplicación de Grad-CAM en diferentes modelos y tareas.

Ejemplo 1 de Grad-CAM: clasificación de imágenes con ResNet50

Como primer ejemplo, se presenta la aplicación de Grad-CAM a un modelo de clasificación de imágenes ampliamente utilizado, ResNet50 (He et al., 2016), entrenado en el conjunto de datos ImageNet1k. En la **Figura 1** se muestran varias instancias de imágenes junto con los mapas de activación generados por Grad-CAM para diferentes clases objetivo. Cada fila corresponde a una instancia diferente, y cada columna representa una clase específica junto con la probabilidad asignada por el modelo a esa instancia para dicha clase.




Figura 1 Aplicación de Grad-CAM a ResNet50 en la tarea de clasificación de imágenes (versión ImageNet1k). En este caso, cada fila corresponde a una instancia diferente y cada columna a una clase presente en ImageNet junto con la probabilidad asignada por este modelo a esa instancia para dicha clase. Se puede observar en detalle cómo el mapa de calor generado por Grad-CAM resalta las regiones de la imagen que son más relevantes para la predicción de una clase específica. Principalmente en la diagonal de la figura donde la imagen corresponde con la clase parecen ser explicaciones más concordantes con lo esperado, pero a la vez fuera de la diagonal se puede ver como cambia la explicación cuando no hay correspondencia entre la clase y la imagen. Por ejemplo, cuando la imagen contiene un *chita* y se evalúa la clase *avión*, el mapa de calor resalta una región en la parte superior de la imagen que contiene el cielo, lo que podría interpretarse como un feature que contribuye a la activación de la clase avión. Algo similar ocurre con la imagen del avión para la activación correspondiente a auto deportivo, se observa que el modelo resalta las superficies planas del ala del avión, posiblemente debido a un feature propio de objetos artificiales.

La **Figura 1** revela dos cosas, primero que Grad-CAM parece resaltar regiones que a priori un humano juzgaría relacionadas con la clase representada por la instancia (resultado que muestran en el trabajo original), y segundo, demuestra que el modelo evaluado en este caso es capaz de localizar con alta precisión los objetos correctos y mantiene el foco en el sujeto relevante incluso cuando discrimina entre clases semánticamente similares, como diferentes tipos de felinos, dirigiendo su atención por defecto al objeto más prominente cuando la clase es incorrecta. De esta manera, Grad-CAM expone las decisiones internas y los posibles sesgos del modelo, como cuando asocia la textura de la reja de fondo en la foto del perro con un tipo de gato atigrado (*tiger cat*) o el pico del pájaro con la clase "flamengo". Grad-CAM funciona entonces como una potente herramienta de diagnóstico que no solo valida el razonamiento del modelo, sino que también puede evidenciar sesgos en el comportamiento del modelo brindando información que permita entender que pasa detrás de sus errores.

Ejemplo 2 de Grad-CAM en Captioning con BLIP

Como mencionamos previamente, podemos aplicar Grad-CAM a tareas más allá de la clasificación de imágenes, y en este caso vamos a ver como Grad-CAM puede adaptarse a la tarea de generación automática de subtítulos (automatic captioning). No solo eso, sino que también se puede extender a modelos multimodales basados en transformers, que combinan procesamiento de imágenes y texto. Para este ejemplo, se utilizó el modelo BLIP (Li et al., 2022), un sistema de visión y lenguaje que combina un codificador visual con un codificador textual para realizar tareas como image-text matching y generación de subtítulos.

La adaptación de Grad-CAM a BLIP permite localizar las regiones de la imagen relevantes para cada token del texto en dicha tarea. Para poder aplicarlo en este contexto, se realizaron las siguientes modificaciones (ver: <https://github.com/salesforce/LAVIS>):

- Capa utilizada: un bloque de cross-attention del transformador multimodal (por defecto, el 6°).
- Cálculo de gradientes: se realiza sobre la salida del bloque de cross-attention.
- Propagación hacia atrás: se obtiene el gradiente de la salida del bloque de cross-attention con respecto a la entrada de la imagen.
- Cálculo de pesos: se promedian los gradientes sobre las dimensiones espaciales para obtener un peso por canal.
- Generación del mapa de activación: se combina el mapa de activación ponderado con los pesos obtenidos y se aplica ReLU para obtener el mapa final.



Figura 2 Como se puede aplicar Grad-CAM a modelos en tareas más complejas como

Captioning, aquí se ve la última capa de atención del decoder de BLIP, y cómo se van generando los mapas de activación para cada palabra del caption generado.

Como se observa en la **Figura 2**, Grad-CAM logra identificar regiones relevantes de la imagen asociadas a cada palabra del subtítulo generado. Por ejemplo, para la palabra "dog" (perro), el mapa de activación resalta claramente la figura del perro en la imagen. De manera similar, para "horse" (caballo), el mapa se enfoca en el objeto que está en el fondo. Este análisis detallado demuestra cómo el modelo BLIP utiliza información visual específica para generar cada token del texto, proporcionando una explicación clara y visual del proceso de generación de subtítulos. Una de las observaciones más interesantes es que incluso podemos ver las activaciones relacionadas a preposiciones y como el modelo interpreta la relación espacial entre los objetos en la imagen. Por ejemplo, para la palabra "on" (sobre), el modelo resalta las patas del gato que fue el token previo que observó (recordemos que los modelos de transformers generan el texto de manera autoregresiva, es decir, palabra por palabra, condicionando cada token en los previos), o incluso en "and" entre los dos sustantivos, el modelo resalta la zona entre ambos objetos.

Ejemplo 3 de varias arquitecturas en clasificación de imágenes

Una pregunta válida es: ¿cómo se comporta Grad-CAM en diferentes arquitecturas de redes neuronales? A continuación, se presenta un ejemplo de cómo Grad-CAM se aplica a diferentes arquitecturas de redes neuronales en la tarea de clasificación de imágenes. Se utilizarán las mismas imágenes de instancia que en el ejemplo anterior para evaluar cómo cada modelo localiza la evidencia visual para las clases objetivo.




Figura 3 Comparación entre los mapas Grad-CAM de tres arquitecturas de redes neuronales de visión por computadora: ResNet50, VGG16 (representantes de las Redes Neuronales Convolucionales o CNNs) y ViT-B/16 (un Vision Transformer moderno). Se utilizan tres imágenes de instancia diversas para evaluar cómo cada modelo localiza la evidencia visual para cinco clases de destino diferentes de IMAGENET1k. Los mapas de calor (Grad-CAM) indican las regiones de la imagen que más influyeron en la decisión del modelo, mientras

que el porcentaje (pred) debajo de cada mapa muestra la confianza (probabilidad Softmax) que el modelo asignó a esa clase específica para esa imagen.

Al comparar diferentes arquitecturas, Grad-CAM revela una dicotomía fundamental en los mecanismos de razonamiento visual: mientras las CNNs como ResNet50 y VGG16 destacan por su precisa localización espacial, basando su confianza en características intrínsecas del objeto (como se ve en el avión), el Vision Transformer (ViT) utiliza un enfoque de contexto global. Este último genera mapas de atención más difusos pero puede alcanzar una confianza sorprendentemente alta al interpretar la escena completa, como lo demuestra al clasificar el caballo basándose en el entorno de "animales en un campo" y al asociar fuertemente el avión con el cielo. En esencia, la visualización no muestra un fallo del ViT, sino su diferente estrategia de inferencia, más contextual y menos localizada que la de las CNNs.

Cabe destacar que la aplicación en este caso de Grad-CAM a Vision Transformers (ViT) es menos directa que en CNNs, ya que los ViT no tienen capas convolucionales tradicionales. Nosotros aplicamos el método a la salida del Decoder del ViT (sugerido por los autores), que contiene información global de la imagen a través de los tokens de atención. Puede ser interesante explorar otras variantes de Grad-CAM diseñadas específicamente para Transformers, como **ViT-Grad-CAM** (ver: <https://github.com/Mikael17125/ViT-GradCAM>), que podrían ofrecer una mejor alineación con la arquitectura subyacente y mejorar la calidad de las explicaciones visuales.

4. Más allá de Grad-CAM

Con la intención de mejorar la definición y la estabilidad de los mapas de calor explicativos, se han propuesto diversas variantes de Grad-CAM. Estas buscan refinar la localización, reducir la dependencia de los gradientes o aumentar la resolución espacial de las visualizaciones. Entre ellas usaremos también una incluida en el trabajo original que es Guided Grad-CAM (2017). Esta técnica combina Grad-CAM con Guided Backpropagation para obtener mapas de calor de alta resolución que resaltan detalles finos y bordes, proporcionando una visualización más clara de las regiones relevantes para la predicción. Algunas de las variantes más destacadas son:

Grad-CAM++ (2018)

- **Idea:** ajusta la forma de calcular los pesos α_k^c para tener en cuenta múltiples instancias de un mismo objeto en la imagen. En lugar de promediar los gradientes, utiliza una combinación ponderada que enfatiza las regiones con activaciones más fuertes utilizando derivadas de segundo orden.
- **Ventajas:** produce mapas más precisos en escenarios complejos y con objetos superpuestos.

- **Desventajas:** mayor costo computacional y complejidad en el cálculo.

Score-CAM (2019)

- **Idea:** evita el uso directo de los gradientes, utilizando en su lugar las activaciones de la capa convolucional para generar mapas de calor. Cada mapa de activación se normaliza y se utiliza para ponderar la entrada, evaluando cómo cambia la predicción del modelo.
- **Ventajas:** no depende de los gradientes, lo que puede mejorar la estabilidad y la interpretabilidad.
- **Desventajas:** requiere múltiples evaluaciones del modelo, aumentando el costo computacional.

HiRes-CAM (2020)

- **Idea:** combina Grad-CAM con técnicas de superresolución para mejorar la resolución espacial de los mapas de calor. Utiliza interpolación y refinamiento basado en los gradientes para obtener visualizaciones más detalladas.
- **Ventajas:** mapas de calor con mayor detalle y definición.
- **Desventajas:** mayor complejidad y costo computacional.

Ablation-CAM (2020)

- **Idea:** se basa en la idea de ablation, eliminando sistemáticamente partes de la entrada para evaluar su impacto en la predicción. Genera mapas de calor al medir cómo cambia la salida del modelo cuando se ocultan diferentes regiones. Similar a la idea de Occlusion Maps, pero aplicado a las activaciones internas del modelo.
- **Ventajas:** proporciona una medida directa de la importancia de cada región.
- **Desventajas:** computacionalmente costoso y puede ser menos estable que los métodos basados en gradientes.

Comparación de métodos de explicabilidad basados en Grad-CAM




Figura 4: Comparación de cinco métodos de atribución visual (GradCAM, GradCAM++, HiResCAM, AblationCAM y Guided GradCAM) aplicados a una imagen de entrada compleja. Cada fila muestra los mapas de activación generados por un método diferente para cinco clases de destino de ImageNet ("Tiger Cat", "Golden Retriever", "Zebra", "Plane", "Trailer Truck"). La visualización permite evaluar y contrastar la precisión en la localización de objetos, la especificidad de clase y el nivel de detalle que ofrece cada técnica de interpretabilidad.

El análisis de los métodos basados en mapas de calor (GradCAM, GradCAM++, HiResCAM, AblationCAM) demuestra su gran eficacia para localizar correctamente los objetos de interés, como el gato y el perro, siendo las variantes más avanzadas como HiResCAM y AblationCAM las que ofrecen una mayor nitidez y fidelidad a los contornos. Más importante aún, estas técnicas revelan como los modelos resuelven la incertidumbre: la atención se desvía a objetos semánticamente similares (los caballos por la "Zebra") o a características contextuales aprendidas cuando la clase está ausente, como resaltar el cielo para la clase "Plane".

En contraste, Guided GradCAM opera a un nivel de detalle mucho más profundo, respondiendo no a "dónde" mira el modelo, sino a "qué píxeles específicos" dentro de esa región son importantes. Al resaltar texturas finas como el pelaje del gato, los bigotes o los bordes, esta técnica ofrece una evidencia granular de las características exactas que fundamentan la decisión. En conjunto, la figura demuestra que mientras los mapas de calor son ideales para una evaluación de localización general, Guided GradCAM es una herramienta de "zoom" para un análisis forense de los atributos visuales que el modelo realmente utiliza.

Aunque searía necesario cuantificar la diferencia entre estos métodos de explicación, al revisar la **Figura 4**, las alternativas posteriores a Grad-CAM no parecen arrojar resultados drásticamente diferentes, y lo que es más, estas alternativas también introducen nuevas complejidades y costos computacionales. La elección del método más adecuado dependerá del contexto específico, los recursos disponibles y el nivel de detalle requerido para la interpretación.

5. Conclusión

A lo largo de este análisis, mostramos la importancia que tienen Grad-CAM y sus variantes más allá de una simple herramientas de visualización ya que se han convertido en instrumentos de diagnóstico indispensables para la auditoría y comprensión profunda de los modelos de visión por computadora. Las conclusiones extraídas de las figuras presentadas convergen en una idea central: la capacidad de Grad-CAM para "abrir la caja negra" nos permite entender no solo qué decide un modelo, sino cómo y por qué.

Si bien Grad-CAM es una aproximación y no el reflejo completo del complejo proceso de inferencia de una red, su capacidad para traducir las decisiones abstractas de un modelo en evidencia visual e interpretable es fundamental. Permite a los desarrolladores e investigadores no solo celebrar los éxitos, sino también entender, cuestionar y mitigar los fallos, identificar sesgos y, en última instancia, construir sistemas de inteligencia artificial más robustos, fiables y transparentes.

Referencias:

- Zeiler, M. D., & Fergus, R. (2014). *Visualizing and Understanding Convolutional Networks*. In ECCV. Springer. [Paper Occlusion Maps](#)
- Springenberg, J. T., Dosovitskiy, A., Brox, T., & Riedmiller, M. (2014). *Striving for Simplicity: The All Convolutional Net*. arXiv:1412.6806. [Paper Guided Backpropagation](#)
- Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., & Torralba, A. (2016). *Learning Deep Features for Discriminative Localization*. CVPR. [Paper CAM](#)

- He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. CVPR. [Paper ResNet](#)
- Selvaraju, R. R., et al. (2017). *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization*. ICCV. [Paper Grad-CAM](#)
- Chattopadhyay, A., Sarkar, A., Howlader, P., & V. (2018). *Grad-CAM++: Improved Visual Explanations for Deep Convolutional Networks*. arXiv:1710.11063. [Paper Grad-CAM++](#)
- Montavon, G., Samek, W., & Müller, K. R. (2018). *Methods for interpreting and understanding deep neural networks*. Digital Signal Processing, 73, 1–15. [Paper Interpretability](#)
- Samek, W., Montavon, G., Vedaldi, A., Hansen, L. K., & Müller, K. R. (Eds.). (2019). *Explainable AI: Interpreting, Explaining and Visualizing Deep Learning*. Springer. [Book Explainable AI](#)
- Li, J., Li, D., Xiong, C., & Hoi, S. (2022). *BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation*. arXiv preprint arXiv:2201.12086. [Paper BLIP](#)